

Introduction :

Define and compare the roles of the chromosome and plasmids in *Enterococcus faecium*. Why are both included in the definition of the bacterium's genome?

1. Définitions et Rôles Comparés

Chez *Enterococcus faecium*, comme chez la plupart des bactéries, l'information génétique est répartie entre deux types de molécules d'ADN distinctes par leur fonction et leur stabilité.

A. Le Chromosome : Le "Cœur" Fonctionnel

Le chromosome est la structure génétique principale et indispensable.

- **Rôle** : Il porte les **gènes essentiels** (gènes de ménage) nécessaires à la survie de la bactérie, à sa réplication, et à son métabolisme de base (synthèse des protéines, de la paroi, production d'énergie).
- **Chez *E. faecium* E745** : Il s'agit d'une molécule d'ADN circulaire unique d'environ 2,7 à 2,8 Mb.
- **Contenu spécifique** : Il contient également des gènes de résistance intrinsèque (comme *msrC* pour les macrolides) et des facteurs de virulence majeurs ancrés à la paroi comme le gène *acm* (adhésine liant le collagène), qui sont stables et propres à l'espèce.

B. Les Plasmides : Les "Outils" d'Adaptation (Accessoires)

Les plasmides sont des molécules d'ADN extracromosomiques, généralement circulaires et plus petites.

- **Rôle** : Ils portent des **gènes accessoires** qui ne sont pas indispensables dans un environnement idéal, mais qui confèrent un avantage sélectif crucial sous stress (ex: présence d'antibiotiques). Ils agissent comme des "modules d'extension" interchangeables.
- **Chez *E. faecium* E745** : La souche contient 6 plasmides de tailles variables (de 9,3 kb à 223 kb).
- **Contenu spécifique** : C'est sur les plasmides que se trouvent les déterminants majeurs de la multirésistance, notamment le cluster génique ***vanA*** (résistance à la vancomycine) situé sur le plasmide pE745-2, ou le gène *dfrG* (triméthoprime).

2. Tableau Comparatif

Caractéristique	Chromosome	Plasmides
Taille	Grand (~2.8 Mb pour E745)	Variable, généralement petit (9kb - 223kb)

Nombre de copies	Généralement 1 copie par cellule	Variable (nombre de copies souvent plus élevé)
Fonction	Essentielle (Survie, Croissance)	Adaptative (Résistance, Virulence spécifique)
Stabilité	Très stable (transmission verticale stricte)	Mobile (peut être perdu ou acquis par conjugaison)
Exemple (E745)	Porte le gène de virulence <i>acm</i>	Porte le gène de résistance <i>vanA</i>

3. Pourquoi inclure les deux dans la définition du génome ?

Bien que le chromosome définisse l'identité de l'espèce (*qui* est la bactérie), le génome complet (ou "pan-génome" de la souche) inclut obligatoirement les plasmides pour trois raisons scientifiques et cliniques majeures :

1. **La définition du phénotype clinique** : Dans le contexte médical (E-Santé), ce qui importe est la capacité de la bactérie à survivre au traitement. Si l'on exclut les plasmides de la définition du génome de *E. faecium* E745, on ignore la résistance à la vancomycine (*vanA* est plasmidique). On définirait alors la bactérie comme "sensible", ce qui serait une erreur fatale pour le patient.
2. **L'Interdépendance fonctionnelle** : Les gènes plasmidiques et chromosomiques interagissent. Par exemple, le chromosome fournit la machinerie cellulaire nécessaire à l'expression des gènes de résistance portés par les plasmides. Le "génome" représente l'ensemble du potentiel métabolique et pathogène de l'organisme à un instant T.
3. **L'Épidémiologie et la Mobilité** : L'article de Zhang *et al.* insiste sur le fait que l'analyse des plasmides est cruciale pour comprendre la dissémination de la résistance. Le génome bactérien est dynamique ; inclure les plasmides permet de tracer les événements de transfert horizontal de gènes (HGT) entre différentes souches bactériennes.

What types of genes are likely found on the chromosome versus the plasmids in *Enterococcus faecium*? Give examples and explain how they benefit the bacterium.

Voici la distinction des types de gènes présents sur le chromosome par rapport aux plasmides chez *Enterococcus faecium*, basée sur les données génomiques de la souche E745 décrites dans l'article de Zhang *et al.*

Cette répartition reflète la dichotomie biologique entre les fonctions vitales (stables) et les fonctions adaptatives (mobiles).

1. Sur le Chromosome : Les fonctions essentielles et intrinsèques

Le chromosome porte l'information génétique définissant l'identité de l'espèce et assurant sa survie basale. On y trouve principalement des gènes "de ménage" (*housekeeping genes*) et des facteurs de virulence conservés.

- **Types de gènes :**
 - **Gènes métaboliques essentiels** : Nécessaires à la réplication, à la synthèse de la paroi et au métabolisme central.
 - **Gènes de virulence intrinsèques** : Facteurs d'adhésion présents chez la plupart des souches de l'espèce.
 - **Gènes de résistance intrinsèque** : Résistances chromosomiques naturelles, non acquises par transfert horizontal récent.
- **Exemples concrets chez *E. faecium* E745 :**
 - **Gène *acm*** : Code pour une protéine de liaison au collagène ("Adhesin of Collagen of *E. faecium*").
 - *Bénéfice* : Permet à la bactérie d'adhérer aux tissus de l'hôte, facilitant la colonisation et l'infection.
 - **Gène *msrC*** : Code pour une protéine conférant une résistance faible aux macrolides.
 - *Bénéfice* : Fournit une protection de base (intrinsèque) contre certains antibiotiques.
 - **Gènes *pyrK_2* et *purH*** : Impliqués dans la biosynthèse des purines et pyrimidines.
 - *Bénéfice* : Essentiels pour la croissance bactérienne dans des milieux pauvres en nucléotides, comme le sérum sanguin humain.

2. Sur les Plasmides : L'adaptation rapide et la multirésistance

Les plasmides portent des gènes "accessoires" qui ne sont pas indispensables à la vie cellulaire normale mais qui offrent un avantage sélectif critique dans des environnements hostiles (hôpitaux, présence d'antibiotiques).

- **Types de gènes :**
 - **Gènes de résistance acquise** : Souvent regroupés en cassettes ou transposons, ils confèrent des résistances de haut niveau.
 - **Éléments mobiles** : Gènes permettant la conjugaison et le transfert du plasmide à d'autres bactéries.
- **Exemples concrets chez *E. faecium* E745 :**
 - **Cluster *vanA* (sur pE745-2)** : L'opéron complet de résistance à la vancomycine.

- *Bénéfice* : Confère une résistance de haut niveau à la vancomycine, un antibiotique de dernier recours, permettant la survie du pathogène lors des traitements sévères.
- **Gène *dfrG* (sur pE745-6)** : Résistance au triméthoprim.
- *Bénéfice* : Permet de résister aux inhibiteurs de la synthèse des folates.
- **Gènes *erm(B)* et *tet(M)* (sur pE745-1, -2, -4, -5)** : Résistances respectives à l'érythromycine et à la tétracycline.
- *Bénéfice* : Confère un phénotype de multirésistance (MDR), rendant la bactérie invulnérable à plusieurs classes d'antibiotiques simultanément.

Résumé Comparatif

Localisation	Type de Gènes	Fonction Principale	Exemples E745
Chromosome	Essentiels / Intrinsèques	Maintenance, Réplication, Adhésion (Virulence)	<i>acm</i> (adhésion), <i>msrC</i> (résistance basale), <i>purH</i> (métabolisme)
Plasmides	Accessoires / Acquis	Adaptation au stress, Résistance aux antibiotiques	<i>vanA</i> (vancomycine), <i>dfrG</i> (triméthoprim), <i>tet(M)</i> (tétracycline)

Explain why it is important to include both chromosomal and plasmid DNA when sequencing and assembling the complete genome of *Enterococcus faecium*.

Il est crucial d'inclure à la fois l'ADN chromosomique et l'ADN plasmidique lors du séquençage et de l'assemblage du génome d'*Enterococcus faecium* pour obtenir une vision complète et cliniquement pertinente de la bactérie. Voici pourquoi, en se basant sur l'étude de la souche E745 :

1. La localisation de la résistance aux antibiotiques (Enjeu Clinique)

Chez *Enterococcus faecium*, les déterminants de la résistance aux antibiotiques ne sont pas uniformément répartis.

- Si l'on ne séquençait que le chromosome, on identifierait la souche E745 comme une bactérie possédant des gènes de ménage standards et quelques résistances mineures (ex: *msrC*).
- Cependant, la résistance critique à la **vancomycine** (qui définit la dangerosité clinique de cette souche VRE) est portée par le **cluster de gènes *vanA***, qui est situé sur le **plasmide pE745-2** et non sur le chromosome.
- Ignorer les plasmides reviendrait donc à passer à côté de la caractéristique principale de la souche : sa multirésistance.

2. La compréhension de la dynamique évolutive (Enjeu Épidémiologique)

Les plasmides sont des éléments génétiques mobiles. Les inclure dans l'assemblage permet de comprendre comment la résistance se propage :

- Le séquençage complet permet de caractériser les **mécanismes de transfert horizontal** (HGT). L'étude montre que les plasmides de la souche E745 contiennent des séquences de transposons et des systèmes de conjugaison qui facilitent la dissémination de la résistance *vanA* vers d'autres bactéries (même d'espèces différentes comme *S. aureus*).
- Une vision limitée au chromosome ne permettrait pas de tracer ces voies de transmission lors d'une épidémie hospitalière.

3. La complétude biologique (Enjeu Structurel)

L'assemblage hybride (Illumina + PacBio) a pour but de produire un génome "fini" et circulaire.

- Les plasmides représentent une part significative de l'information génétique totale (le "pan-génome"). Dans le cas de E745, il y a **6 plasmides** distincts, allant de 9 kb à 223 kb.
- Ces plasmides portent également des gènes de maintenance (*toxine-antitoxine*) qui assurent leur stabilité dans la cellule. Les exclure donnerait une image faussée de la biologie de la souche.


En résumé : Le chromosome définit l'**identité** de l'espèce (*qui* est la bactérie), tandis que les plasmides définissent son **profil de résistance et de virulence** (*ce qu'elle est capable de faire*). Pour un projet de E-santé visant à surveiller les infections nosocomiales, l'analyse des plasmides est aussi, voire plus importante, que celle du chromosome.

Discuss the importance of plasmids in bacterial evolution. How can studying plasmids in *Enterococcus faecium* inform us about the potential spread of antibiotic resistance genes to other bacterial species?

1. Le rôle des plasmides dans l'évolution bactérienne

Les plasmides sont les principaux moteurs du **Transfert Horizontal de Gènes (HGT)**, agissant comme un accélérateur évolutif pour les bactéries.

- **"Sauts Quantiques" vs Gradualisme** : Contrairement à l'évolution chromosomique qui repose sur l'accumulation lente de mutations aléatoires (transmission verticale), les plasmides permettent aux bactéries d'acquérir des traits adaptatifs complexes et entièrement fonctionnels (comme la résistance ou la virulence) en un seul événement.
- **Plasticité Génétique** : Les plasmides représentent le "génomme accessoire". Ils permettent aux bactéries de s'adapter rapidement aux stress environnementaux (comme la présence d'antibiotiques à l'hôpital) sans altérer les gènes essentiels ("de ménage") présents sur le chromosome.
- **Facilitation de la Dissémination** : Grâce à la **conjugaison** (accouplement bactérien), les plasmides peuvent être transférés entre différentes cellules bactériennes, et surtout, entre différentes espèces. Cela transforme un avantage de survie individuel en un trait communautaire.



2. L'étude d'*E. faecium* E745 comme modèle prédictif

L'étude des plasmides d'*E. faecium* E745 fournit un modèle concret de la manière dont la résistance se propage à d'autres pathogènes.

A. Le cluster *vanA* : Une "bombe" génétique mobile

Le séquençage d'E745 révèle que la résistance de haut niveau à la vancomycine n'est pas intrinsèque (chromosomique) mais portée par un plasmide spécifique, **pE745-2** (32,4 kb).

- **Transposon Tn1546** : Le cluster de gènes *vanA* (comprenant *vanR*, *vanS*, *vanH*, *vanA*, *vanX*, *vanY*, *vanZ*) est situé à l'intérieur d'un élément transposable appelé **Tn1546** sur ce plasmide. Les transposons sont des "gènes sauteurs" qui peuvent se déplacer d'un plasmide au chromosome ou vers d'autres plasmides, augmentant ainsi la mobilité de la résistance.

- **Implication** : La présence de *vanA* sur un plasmide mobile explique pourquoi *E. faecium* est rapidement devenu une cause majeure d'infections nosocomiales (VRE - Entérocoques Résistants à la Vancomycine) par rapport aux espèces où la résistance est chromosomique et moins mobile.

B. La menace du transfert inter-espèces (VRSA)

L'analyse des séquences plasmidiques nous informe sur le potentiel de **transmission inter-espèces**.

- **Homologie avec *S. aureus*** : L'article souligne que les plasmides trouvés chez *E. faecium* partagent une homologie structurelle significative avec des plasmides trouvés chez *Staphylococcus aureus*.
- **Le cauchemar clinique** : Cette homologie suggère qu'*E. faecium* agit comme un **réservoir**. Il peut transférer le plasmide *vanA* au *Staphylococcus aureus* résistant à la méthicilline (SARM/MRSA), créant ainsi un **VRSA** (*S. aureus* Résistant à la Vancomycine), une super-bactérie pratiquement intraitable.
- **Mécanismes de stabilité** : L'analyse de pE745-2 a également révélé un **système toxine-antitoxine** (ω - ϵ - ζ). Ce système tue toute cellule fille qui perdrait le plasmide lors de la division, forçant ainsi la population bactérienne à conserver le gène de résistance même en l'absence de pression antibiotique.

Conclusion

L'étude des plasmides chez *E. faecium* ne consiste pas seulement à cataloguer des gènes ; c'est un outil d'**épidémiologie prédictive**. En identifiant les plasmides spécifiques (comme pE745-2), leur machinerie de transfert (gènes de conjugaison) et leurs systèmes de stabilité (toxine-antitoxine), nous pouvons évaluer le risque que ces gènes sautent vers d'autres pathogènes critiques comme *S. aureus*, justifiant ainsi des mesures d'isolement strictes dans les hôpitaux.

READ PREPROCESSING

FastQC:

What is the structure of a FASTQ file?

Un fichier FASTQ est un format texte standard pour stocker des séquences biologiques et leurs scores de qualité associés. Chaque "read" (lecture) occupe 4 lignes :

Ligne 1 (Header) : Commence par @ suivi de l'identifiant unique de la séquence (ex: instrument, coordonnées du cluster).

Ligne 2 (Séquence) : La suite de nucléotides bruts (A, T, C, G, N).

Ligne 3 (Séparateur) : Commence par +, parfois suivi de l'identifiant (souvent vide pour gagner de la place).

Ligne 4 (Qualité) : Une chaîne de caractères ASCII codant le score de qualité pour chaque base de la ligne 2.

How is the quality of the data stored in the FASTQ files?

La qualité est stockée sous forme de scores Phred (Q-scores), encodés en caractères ASCII (généralement Phred+33). Chaque caractère correspond à un entier Q qui représente la probabilité d'erreur P selon la formule logarithmique :

$$Q = -10\log_{10}(P)$$

Par exemple, un score Q30 signifie une probabilité d'erreur de 10^{-3} (1 chance sur 1000 que la base soit fausse), ce qui est considéré comme le standard de haute qualité.

How are paired reads identified?

Les lectures appariées (*paired-end*) proviennent du même fragment d'ADN lu par les deux extrémités. Elles sont identifiées :

- **Dans le nom du fichier** : Souvent par **_R1** (Forward) et **_R2** (Reverse) ou **_1** et **_2**.
- **Dans le Header FASTQ** : Par un espace suivi de **1:N:0:** ou **2:N:0:**, ou parfois **/1** et **/2** à la fin de l'identifiant.

How is the quality of your data?

- **Illumina (Short reads)** : Excellente. Les scores Phred sont >Q30 sur toute la longueur (150 pb), sans adaptateurs résiduels.
- **PacBio (Long reads)** : Plus faible (~Q12) avec un taux d'erreur de 10-15%, ce qui est caractéristique et normal pour cette technologie de "single-molecule real-time sequencing".

What can generate the issues you observe in your data? Can these cause any problems during subsequent analyses?

Problèmes possibles : Dégradation de la qualité en fin de read (Illumina), bruit de fond stochastique (PacBio), présence d'adaptateurs.

Conséquences :

- Les bases de faible qualité peuvent créer de faux SNPs (erreurs d'appel de variantes) ou empêcher l'assemblage (graphe de De Bruijn trop complexe).
- Les adaptateurs non retirés empêchent le mapping correct.
- Pour PacBio, le fort taux d'erreur génère des *frameshifts* (décalages du cadre de lecture) s'ils ne sont pas corrigés, rendant l'annotation des gènes impossible.

Mapping:

What percentage of your reads map back to your contigs? Why do you think that is?

Le taux d'alignement des lectures sur les contigs est excellent, avoisinant les 98,9%. Le tableau indique une quantité négligeable de lectures non alignées

("Unassigned_Unmapped"), environ 3 000 pour un total de plus de 260 000 lectures par échantillon. Ce résultat quasi-parfait s'explique par l'alignement des lectures RNA-seq sur l'assemblage de novo généré à partir de la même souche biologique, ce qui garantit une correspondance génétique exacte entre les transcrits et la référence.

What potential issues can cause mRNA reads not to map properly to genes in the chromosome?

Le défaut d'assignation d'une lecture à un gène provient généralement d'une inadéquation entre l'alignement physique et l'annotation fournie. Une cause majeure est l'absence de certaines caractéristiques dans le fichier d'annotation, comme les régions non traduites (UTR) ou les petits ARN régulateurs, qui sont transcrits mais non marqués comme gènes. D'autres facteurs incluent la contamination par de l'ADN génomique, le chevauchement physique de deux gènes ou la présence de séquences répétées multiples (multi-mapping) qui empêchent l'algorithme d'attribuer la lecture à un locus unique.

Do you expect this to differ between prokaryotic and eukaryotic projects?

Oui, l'approche diffère fondamentalement en raison de la structure des gènes. Contrairement aux procaryotes, les gènes eucaryotes contiennent des introns qui sont excisés lors de la maturation des ARNm. L'alignement nécessite donc des outils "splice-aware" capables de gérer les jonctions exon-exon discontinues, ce que ne fait pas un aligneur standard comme Bowtie2. De plus, la densité génique étant beaucoup plus faible chez les eucaryotes, la proportion de lectures tombant dans les régions intergéniques serait massivement plus élevée sans une étape de sélection spécifique des ARNm (Poly-A) avant le séquençage.

What percentage of reads map to genes?

Le pourcentage de lectures assignées aux gènes (CDS) varie fortement selon la condition biologique. Il est élevé en milieu BHI, atteignant environ 87,5% (ex: 244 081 lectures assignées sur un total d'environ 279 000 pour l'échantillon 4). En revanche, ce taux chute à environ 63,6% en milieu Sérum (ex: 167 972 lectures assignées sur un total d'environ 264 000 pour l'échantillon 1). Cette baisse sous stress indique une redirection de l'activité transcriptionnelle vers des régions non codantes (intergéniques) non incluses dans le comptage standard.

How many reads do not map to genes? What does that mean? How does that relate to the type of sequencing data you are mapping?

Dans les échantillons traités au Sérum, environ 33% des lectures ne s'alignent pas sur les gènes (contre seulement 7% en BHI). Ces lectures classées "Unassigned_NoFeatures" s'alignent bien sur le génome mais tombent dans des régions intergéniques. Cela est typique du séquençage RNA-seq total qui capture aussi les régions non traduites (UTR) et

les petits ARN régulateurs (sRNA), souvent exprimés en réponse au stress mais non annotés comme séquences codantes (CDS) par Prokka.

What do you interpret from your read coverage differences across the genome?

Les variations de la profondeur de couverture le long du génome reflètent directement les différences d'abondance des transcrits. Une couverture élevée indique un gène fortement exprimé, tandis qu'une couverture faible signale une transcription basale ou nulle. La différence de hauteur de couverture pour une même région entre les conditions Sérum et BHI matérialise physiquement la régulation différentielle, fournissant la donnée quantitative nécessaire au calcul du "Log2 Fold Change" par DESeq2.

Do you see big differences between replicates?

Non, les réplicats biologiques sont homogènes. En observant la ligne "Assigned" du rapport FeatureCounts, on constate que les trois échantillons du groupe Sérum présentent des nombres de lectures assignées comparables (167 972, 193 932 et 181 041). Cette cohérence confirme la reproductibilité technique de l'expérience, indiquant que les variations observées par la suite sont bien biologiques et non dues à des biais de manipulation.

Genome Assembly

1) What's the genome size ?

D'après les résultats de l'analyse QUAST sur votre fichier **E754.fasta**, la taille totale du génome assemblé est de 2 997 801 bp (environ 3,0 Mb).

- **Perspicacité** : Cette taille inclut le chromosome principal (~2,77 Mb) ainsi que les 6 plasmides. C'est une taille classique pour *Enterococcus faecium*, ce qui indique qu'il n'y a pas eu de contamination majeure par un autre organisme (qui aurait gonflé la taille) ni de perte significative de séquence.

2) Report from the paper the accession numbers of the submitted sequences.

L'article de référence (Zhang *et al.*) a déposé les séquences "finies" dans la base de données GenBank sous les numéros suivants :

- **CP018500** : Le Chromosome.
- **CP018501 à CP018506** : Les 6 plasmides (pE745-1 à pE745-6).
- **SRR5153246 & SRR5153247** : Les données brutes (Reads Illumina et PacBio).

3) How many contigs do you expect? How many do you obtain?

- **Attendu (Expect)** : Biologiquement, la souche *E. faecium* E745 possède 1 chromosome et 6 plasmides circulaires décrits dans l'article. On s'attend donc idéalement à **7 contigs** distincts représentant chacun une molécule d'ADN fermée.
- **Obtenu (Obtain)** : Votre rapport QUAST indique exactement **7 contigs** ("# contigs: 7").

- **Interprétation** : C'est un résultat parfait. Cela prouve que l'approche hybride (Illumina + PacBio) a réussi à résoudre toutes les régions répétées qui fragmentent habituellement les assemblages, aboutissant à un génome "fini" (Finished Genome).

4) What is the difference between a 'contig' and a 'unitig'?

C'est une distinction technique liée aux graphes d'assemblage (Graphes de De Bruijn) :

- **Unitig (Unitary Contig)** : C'est une séquence assemblée de haute confiance, correspondant à un chemin **unique et sans ambiguïté** dans le graphe. Dès qu'il y a un embranchement (plusieurs possibilités de suite, souvent à cause d'une répétition), l'unitig s'arrête.
- **Contig** : C'est une séquence plus longue formée par l'assemblage de plusieurs unitigs. L'assembleur prend des décisions pour résoudre les ambiguïtés (en utilisant par exemple les *paired-end reads* pour sauter par-dessus une répétition) et fusionner les unitigs.
- **En résumé** : Les unitigs sont les briques de base sûres à 100%, les contigs sont les murs construits avec ces briques.

5) What is the difference between a 'contig' and a 'scaffold'?

Contig : Une séquence continue de nucléotides (A, C, T, G) sans aucune interruption connue. L'ordre des bases est déterminé.

Scaffold (Échafaudage) : Une structure ordonnée composée de plusieurs contigs séparés par des "trous" (*gaps*) de taille estimée. Ces trous sont représentés par des suites de **N** (ex: **ATTCG...NNNN...GCTAG**). On connaît l'ordre et l'orientation des contigs, mais il manque la séquence exacte entre eux.

Dans votre projet : Le rapport QUAST montre "**# N's per 100 kbp: 0.00**". Vous n'avez que des contigs pleins, pas de scaffolds à trous, grâce à la qualité des Long Reads.

6) What are the k-mers? What k-mer(s) should you use?

Définition : Un k-mer est une sous-chaîne de longueur **\$k\$** extraite d'une lecture. (Exemple pour **ATCGT** avec $k=3$: **ATC**, **TCG**, **CGT**). Ils servent à construire le graphe de De Bruijn pour l'assemblage.

Choix : Il est recommandé d'utiliser une approche **multi-kmer** (utilisée par des assembleurs comme SPAdes). On lance l'assemblage avec plusieurs tailles (ex: $k=21, 33, 55, 77$) pour combiner les avantages des petits et des grands k-mers.

7) What are the problems and benefits of choosing a small kmer? And a big k-mer?

C'est un compromis classique entre sensibilité et spécificité :

Taille de K	Avantages (Bénéfices)	Inconvénients (Problèmes)

Petit K (ex: 21)	Haute Sensibilité : Permet d'assembler des régions à faible couverture ou avec des erreurs de séquençage (car la probabilité d'avoir un k-mer sans erreur est plus grande).	Ambiguïté (Graphe complexe) : Les courtes répétitions du génome (> k) fusionnent dans le graphe, créant des nœuds impossibles à résoudre. Cela donne un assemblage très fragmenté.
Grand K (ex: 127)	Haute Spécificité : Résout les répétitions (si la répétition < k). Le graphe est plus simple et linéaire.	Faible Sensibilité : Nécessite une très haute couverture et qualité. Une seule erreur de séquençage "casse" le k-mer et interrompt l'assemblage.

8) Some assemblers can include a read-correction step before doing the assembly. 9) What is this step doing?

Action : Cette étape utilise la redondance des lectures (la profondeur de séquençage) pour repérer et corriger les erreurs aléatoires.

Mécanisme : Si à une position donnée du génome, on aligne 50 lectures et que 49 indiquent un "A" et une seule indique un "C", l'algorithme considère le "C" comme une erreur de séquençage et le corrige en "A".

Importance pour votre projet : C'est crucial pour l'approche hybride. Les données PacBio brutes ont un taux d'erreur élevé (~10-15%). Avant l'assemblage final, on utilise les données Illumina (très précises) pour corriger les lectures PacBio, ou on corrige l'assemblage final (étape de "Polishing"), garantissant ainsi que les gènes identifiés (comme *vanA*) ont la bonne séquence sans décalage de cadre de lecture (*frameshift*).

Assembly evaluation :

1) What do measures like N50, N90, etc. mean?

Le **N50** est une métrique statistique utilisée pour évaluer la **contiguïté** d'un assemblage.

- Si l'on classe tous les contigs par ordre décroissant de taille, le N50 est la longueur du contig tel que l'ensemble des contigs de cette taille ou plus grands couvre **50%** de la taille totale du génome.
- Votre rapport QUAST indique un **N50 de 2 773 959 pb**. C'est une valeur très élevée.
- Le **N90** suit la même logique pour 90% du génome, permettant d'évaluer la fragmentation des séquences plus petites (souvent les bouts de plasmides ou les régions difficiles).

2) How can they help you evaluate the quality of your assembly?

Elles permettent de déterminer si le génome a été reconstruit en quelques gros morceaux (ce qu'on souhaite) ou s'il est resté fragmenté en milliers de petits morceaux ("en miettes").

- Un N50 proche de la taille totale du chromosome indique que l'assembleur a réussi à franchir les séquences répétées.
- Vous avez un **L50 de 1**. Cela signifie qu'il suffit d'**un seul contig** (le plus grand) pour avoir plus de la moitié du génome. C'est le signe d'une qualité structurale parfaite : le chromosome est entier.

3) Which measure is the best to summarize the quality of the assembly (N50, number of ORFs, completeness, total size, longest contig ...)

Bien que le N50 soit le standard le plus courant, pour un projet visant un "génomome fini" (*finished genome*) comme celui-ci, la meilleure mesure est la combinaison du **Nombre de Contigs** et de la **Taille Totale**.

- Un N50 peut être artificiellement élevé si l'assembleur fusionne par erreur des morceaux qui ne devraient pas l'être (misassembly).
- Le chiffre clé est **7 contigs**. C'est la mesure "reine" ici car elle correspond exactement à la réalité biologique décrite dans l'article : **1 chromosome + 6 plasmides**. Cela valide biologiquement l'assemblage.

4) How does your assembly compare with the reference assembly?

La comparaison de notre assemblage final avec la référence révèle une réussite structurale totale. Nous avons reconstitué l'architecture exacte du génome d'*Enterococcus faecium* en obtenant sept contigs qui correspondent précisément aux sept réplicons biologiques attendus, soit le chromosome et les six plasmides. Cette identité parfaite est confirmée par les métriques de continuité, où notre N50 de 2,76 Mb ne représente pas une simple moyenne statistique mais correspond physiquement à la taille du chromosome entier reconstitué en un seul tenant. De plus, la quasi-superposition de la longueur totale assemblée et du taux de GC avec ceux de la référence démontre que notre approche hybride a capturé l'intégralité de l'information génétique sans introduire de biais de composition ni de contamination.

5) What can have caused the differences?

L'écart minime de longueur observé, où notre assemblage est plus court d'environ 2,7 kilobases par rapport à la référence, est la conséquence technique logique de l'étape de circularisation. Pour fermer physiquement les molécules d'ADN circulaires, l'algorithme d'assemblage doit identifier puis éliminer les séquences chevauchantes identiques aux extrémités des contigs linéaires, ce qui réduit mécaniquement la taille totale affichée. Par ailleurs, il est biologiquement probable que cette différence reflète également la plasticité naturelle des éléments mobiles, la souche clinique séquencée ayant pu subir de légères variations structurales ou micro-délétions dans ses plasmides par rapport à la souche de référence enregistrée dans les bases de données.

6) Why do you think your assembly is better/worse than the public one?

Notre assemblage est qualitativement supérieur aux ébauches génomiques publiques standards car il marque le passage d'un "brouillon" fragmenté à un génome complet ("Gold Standard"), caractérisé par une absence totale de trous de séquençage et une continuité absolue des sept réplicons. Là où un assemblage classique laisse planer le doute sur la localisation des gènes, notre résultat apporte une plus-value clinique décisive en prouvant que le gène de résistance critique *vanA* est situé sur un plasmide autonome et circulaire, et non intégré au chromosome. Cette résolution contextuelle est fondamentale en E-santé car elle confirme le haut potentiel de dissémination horizontale de la résistance, modifiant ainsi l'évaluation du risque épidémique.

1) What type of reads were used for correction (short, paired-end, long reads)?

La correction du génome (polishing) a été réalisée en utilisant exclusivement des lectures courtes Illumina en mode "paired-end" (fichiers [ALL_Illumina_R1.fq.gz](#) et [ALL_Illumina_R2.fq.gz](#)). Cette stratégie permet de compenser le taux d'erreur plus élevé des lectures longues ou de l'assemblage initial en exploitant la très haute fidélité des bases Illumina (Q30+) pour rectifier les substitutions et les petites insertions-délétions (Indels) via l'outil Pilon.

2) What parameters were used in BWA, and how did they impact the results?

C'est parfait, les commandes parlent d'elles-mêmes. Voici les réponses rédigées pour les deux premières questions, basées strictement sur vos scripts.

What type of reads were used for correction (short, paired-end, long reads)?

La correction du génome (polishing) a été réalisée en utilisant exclusivement des lectures courtes Illumina en mode "paired-end" (fichiers [ALL_Illumina_R1.fq.gz](#) et [ALL_Illumina_R2.fq.gz](#)). Cette stratégie permet de compenser le taux d'erreur plus élevé des lectures longues ou de l'assemblage initial en exploitant la très haute fidélité des bases Illumina (Q30+) pour rectifier les substitutions et les petites insertions-délétions (Indels) via l'outil Pilon.

What parameters were used in BWA, and how did they impact the results?

L'alignement a été effectué avec l'algorithme `bwa mem` en utilisant les paramètres par défaut, sans options restrictives supplémentaires. Cet algorithme est spécifiquement conçu pour trouver les "Maximal Exact Matches" et réalise par défaut un alignement local (soft-clipping), ce qui permet aux lectures de s'aligner même si leurs extrémités contiennent des erreurs ou des adaptateurs résiduels. Cette flexibilité est cruciale pour le "polishing", car elle maximise la couverture des régions imparfaites de l'assemblage brut, fournissant ainsi à

Pilon la profondeur de lecture nécessaire pour identifier et corriger les erreurs de consensus avec certitude.

3) Use BLAST to verify whether all the plasmids have been properly assembled.

L'analyse BLASTn réalisée individuellement sur les six contigs plasmidiques valide leur assemblage complet et sans erreur par rapport au génome de référence *E. faecium* E745. Les résultats démontrent une identité de séquence entre 99%-100% et une couverture entre 99%-100% pour l'ensemble des éléments extrachromosomiques. Le contig **E745_Plasmid_1_SuperHybrid** correspond au mégaplasme pE745-1 de 223 kb, et le contig **E745_Plasmid_2_SuperHybrid** s'aligne sur le plasmide pE745-2 porteur de la résistance à la vancomycine. Cette fidélité de reconstruction est confirmée pour les quatre autres plasmides (pE745-3 à pE745-6), attestant de la robustesse de l'approche d'assemblage hybride pour résoudre des structures génomiques.